



图学学报  
*Journal of Graphics*  
ISSN 2095-302X,CN 10-1034/T

## 《图学学报》网络首发论文

题目：面向交通标志的改进 YOLO 目标检测算法  
作者：赵磊, 李栋, 房建东, 曹琪  
收稿日期：2024-04-18  
网络首发日期：2024-06-26  
引用格式：赵磊, 李栋, 房建东, 曹琪. 面向交通标志的改进 YOLO 目标检测算法[J/OL]. 图学学报. <https://link.cnki.net/urlid/10.1034.T.20240625.1439.002>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

## 面向交通标志的改进 YOLO 目标检测算法

赵磊, 李栋, 房建东, 曹琪

(内蒙古工业大学信息工程学院, 内蒙古 呼和浩特 010050)

**摘 要:** 针对当前算法在面对交通标志时存在识别精度低、检测错误较多等问题, 提出了一种基于 YOLOv5 优化的交通标志检测方法。在 Backbone 部分, 为了获得不同大小的感受野, 不同复杂度的特征, 并增强特征图的重要特征, 抑制冗余特征, 使用 DBB 重参数模块代替 Conv 卷积, 并加入 SE 注意力机制; 在 Neck 部分, 设计了新的 SLA Neck, 聚合来自不同层的特征图, 有效防止小目标特征信息损失, 对融合后的特征进行上采样, 增加小目标检测层, 增强浅层语义信息; 在 Head 部分引入 IoU-Aware 查询选择, 即将 IoU 分数引入分类分支的目标函数, 预测框与 GT 的 IoU 作为类别预测的标签, 以实现正样本分类和定位的一致性约束; 使用 SIOU 损失函数代替 CIOU 损失函数, 考虑真实框与预测框之间的方向, 提升收敛速度和推理能力。实验结果表明, 在 TT100K 数据集下, 所提出的改进方法相较于 YOLOv5m, 计算量减少了 3.3%, 参数量减少了 34.8%, 而 mAP、mAP@50:95 分别提升了 13.8% 和 10.4%。实验说明, 该模型在减少模型参数量及大小的同时提高了检测精度, 具有应用价值。

**关 键 词:** 交通标志检测; YOLOv5; 重参数化; 注意力机制; SLA

**中图分类号:** TP391

**文献标识码:** A

**文章编号:** 2095-302X(0000)00-0000-00

## Improved YOLO object detection algorithm for traffic signs

ZHAO Lei, LI Dong, FANG Jiandong, CAO Qi

(School of Information Engineering, Inner Mongolia University of Technology, Hohhot Inner Mongolia 010050, China)

**Abstract:** Concerning the existing problems such as low recognition accuracy and numerous detection errors when the current algorithm confronts traffic signs, a traffic sign detection method based on the optimization of YOLOv5 is put forward. In the Backbone section, the reparameterization module DBB is employed, and convolutions with diverse scales are utilized to obtain receptive fields of various sizes. By means of feature extraction branches with different scales and diverse complexities, the feature space is enriched. Simultaneously, the SE attention mechanism is introduced to enhance the significant features of the feature map and suppress redundant features, thereby enhancing the detection performance of the network; in the Neck section, the SLA Neck is employed as the neck structure, which reduces the number of parameters and the amount of computation while fusing the feature information of different levels, capturing more context information and details, segmenting the background information, enabling the model to be more focused on the target characteristic area, and enhancing the performance of the model when encountering objects of different sizes to achieve precise positioning; concurrently, the fused features are upsampled, and the small object detection layer is added to acquire shallow feature information; in the Head section, the IoU-Aware query selection is introduced, and the IoU score is incorporated into the objective function of the classification branch to achieve the consistent constraint on the classification and localization of the positive samples, and

收稿日期: 2024-04-18; 定稿日期: 2024-06-13

Received: 18 April, 2024; Finalized: 13 June, 2024

基金项目: 内蒙古自治区自然科学基金项目(2022QN06004)

Foundation items: Natural Science Foundation Project of Inner Mongolia Autonomous Region (2022QN06004)

第一作者: 赵磊(1999-), 男, 硕士研究生。主要研究方向为计算机视觉、信息处理与智能控制。E-mail: zhaolei990323@163.com

First author: ZHAO Lei (1999-), master student. His main research interests cover computer vision, information processing and intelligent control.

E-mail: zhaolei990323@163.com

通信作者: 李栋(1984-), 男, 副教授, 博士。主要研究方向为计算机视觉、信息处理与智能控制。E-mail: lidong@imut.edu.cn

Corresponding author: LI Dong (1984-), associate professor, Ph.D. His main research interests cover computer vision, information processing and intelligent control, etc. E-mail: lidong@imut.edu.cn

enhance the matching mechanism of the model, and reduce the occurrences of incorrect detection and missed detection; simultaneously, SIoU is introduced as the loss function, and the direction between the candidate box and the real box is encompassed within the loss range to elevate the detection accuracy. The experimental results indicate that under the TT100K dataset, the proposed improved method, compared with YOLOv5m, reduces the amount of computation by 3.3%, and the number of parameters by 34.8%, while mAP and mAP@50:95 are increased by 13.8% and 10.4% respectively. The experiment demonstrates that the model enhances the detection accuracy while reducing the number of model parameters and size, and possesses application value.

**Keywords:** traffic sign detection; YOLOv5; reparameterization; attention mechanisms; SLA

道路交通标志目标检测算法是一种先进的计算机视觉技术,目的是自动识别道路上的交通标志并提供准确的定位和分类。近年来,随着无人驾驶技术和智能辅助驾驶系统进入高速发展的阶段,对道路上交通标志检测的要求也越来越高。因此设计出一种检测精度高的交通标志检测算法非常有必要。

传统的交通标志检测算法主要是靠人为地去提取交通标志的形状、颜色以及边缘等表层信息进行识别,如基于颜色的方法、基于形状的方法等;还有一种是基于深度学习的卷积神经网络目标检测算法。基于深度学习的检测算法主要分为双阶段和单阶段检测算法,双阶段算法通过提取候选框进行二次修正得到检测结果,代表算法有 R-CNN<sup>[1]</sup>、Fast R-CNN<sup>[2]</sup>、Faster R-CNN<sup>[3]</sup>、Cascade RCNN<sup>[4]</sup>;单阶段算法同时完成定位与分类,代表算法有 YOLO<sup>[5-11]</sup>算法、SSD<sup>[12-13]</sup>算法等;

张毅等<sup>[14]</sup>利用多尺度卷积核的 ResNeXt 来设计改进 Faster-RCNN 的基础网络;HAN 等<sup>[15]</sup>,针对交通标志目标较小的情况,提出了使用小区域提案生成器来提取小交通标志的特征。其都有着不错的精度体现,但是需要先生成候选区域,再去对候选区域进行识别,所以检测时间过长,不能满足实时性。冯爱棋等<sup>[16]</sup>通过融合注意力机制以及视觉 Transformer 来增强对交通标志的关注程度,改善了对小尺寸交通标志的漏检情况。刘紫燕等<sup>[17]</sup>通过改进空间金字塔池化(spatial pyramid pooling, SPP)层以及特征金字塔网络(feature pyramid network, FPN)产生更大尺度的特征图,提高了小尺寸目标的检测精度。杨永波等<sup>[18]</sup>引入了密集空洞卷积 DenseASPP,并将 DenseNet 思想融入到特征链接中,将所有空洞卷积层紧密堆叠以获得更大的感受野和更多尺度的特征图。李大湘等<sup>[19]</sup>引入高效层聚合网络(ALAN),以聚焦目标特征,降低背景环境对目标的影响。YOLO 系列有着良好的检测精度与速度,

基本可以满足交通标志算法该算法的核心思想是通过深度卷积神经网络(CNN)从原始图像中学习特征表示,然后使用预测器生成边界框和类别概率。

交通标志通常目标尺寸小、缺乏足够的视觉特征、很难将其与背景分割开来、某些场景下密集存在,所以无论是两阶段、单阶段,甚至于是 Transformer 算法都不足以很好的完成对于交通标志的检测。为了更好的完成交通标志检测,我们以 YOLOv5 为基准模型设计了改进网络。YOLOv5 整合了大量的优化策略,是一种优秀的检测算法,但其在交通标志上的应用却难以如人意。鉴于此,对 YOLOv5 网络进行改进,以求解决交通标志特征提取难,受背景影响无法关注特征点,检测精度低等问题。本文的主要工作如下:

(1) 引入 DBB 重参数化模块<sup>[20]</sup>,并加入 SE 注意力机制,以求获取不同大小感受野及不同复杂度的多尺度特征,并进行学习,自适应地调整每个通道的特征在后续网络层中的重要性,强特征图的重要特征,抑制冗余特征。

(2) 在 Neck 部分设计了 SLA Neck,使用 SlimNeck 减少参数量与计算量,同时引入改进后的 SSFF、TFE 模块改进特征融合方式,增强特征表示能力。增加小目标检测层,获取浅层特征图。

(3) 引入 RT-DETR 中的 IoU-Aware 查询选择思想,将 IoU 分数引入分类分支的目标函数,将预测框与 GT 的 IoU 作为类别预测的标签,以实现为正样本分类和定位的一致性约束。

(4) 引入 SIoU 损失函数,考虑真实框与预测框之间的方向,加快收敛速度,提升推理能力。

## 1 YOLOv5 结构

YOLOv5 是一种 Single-Stage 目标检测算法,其模型体积较小,处理速度较快,且有着不错的精

度。根据网络网络宽度与深度的不同，可划分为 YOLOv5-N、YOLOv5-S、YOLOv5-M、YOLOv5-L 和 YOLOv5-X 等。主要由四个部分组成：Input、Backbone、Neck、Head。

Backbone(主干)部分主要用于特征提取。针对 Backbone，李跃华等<sup>[21]</sup>引入尺度注意力机制，增强网络的特征提取能力；胡欣等<sup>[22]</sup>引入 MBAM 注意力，加强对不同特征的关注度，增加特征表现能力。魏陈浩等<sup>[23]</sup>增加双层路由注意力模块，以查询自适应的方式去除不相关的区域；它们的目的是增强特征图的重要特征，抑制冗余特征，以此来提高网络的检测性能。

Neck(颈部网络)的主要作用是对多尺度的特征进行融合，生成特征金字塔。Neck 的网络结构设计沿用了 FPN+PAN 的结构。FPN 就是使用一种自顶向下的侧边连接在所有尺度上构建出高级语义特征图。为了补充底层的目标信息，PAN 又加入了自底向上的路线，弥补并加强了定位信息。

Head(输出端)作为最后的预测部分，根据不同

尺寸的特征图来获取不同大小目标物体的类别和位置信息。

## 2 改进网络模型

针对当前传统网络对于交通标志检测特征提取能力不足，导致检测精度低，错检、漏检等严重问题，以 YOLOv5 为基线模型，在该模型基础上进行改进。针对特征提取能力不足的问题，在主干部分引入 DBB 重参数化模块，并加入注意力机制，设计了 DBB-SE 模块；为了增强特征融合能力，并适当减少模型参数，引入了轻量 SlimNeck 作为颈部网络，并在 SlimNeck 中加入了改进后的 SSFF 模块，TFE 模块，同时，增加小目标检测层。抛弃以往的 IoU 匹配策略，优化匹配方式，采用 RT-DETR 中的 IoU-Aware 查询选择匹配策略，提升样本匹配速度与精度，并使用 SIoU 回归损失函数加快收敛速度。其网络结构如图 1 所示。

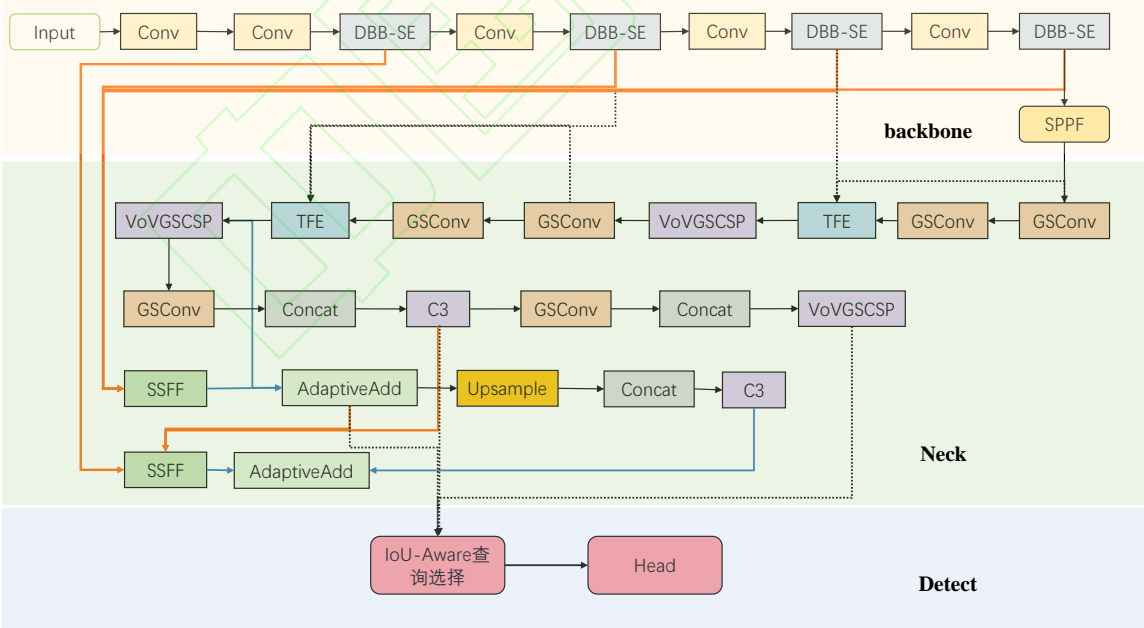


图 1 改进后网络结构图

Fig. 1 Improved network structure diagram

### 2.1 DBB-SE

多分支结构相较于单分枝结构来说，其实验效果要优于单分枝结构，但是使用多分支结构会带来较大的计算量和参数量。重参数化模块的提出为我

们解决了这些问题。重参数化模块将单分支结构与多分支结构进行了融合，在训练阶段使用多分支并行结构，而在推理时使用单分枝结构，有效的完成检测工作。



DBB<sup>[20]</sup>(Diverse Branch Block)重参数化模块,如图 2 所示,在训练中采用分离分支结构,其组合了不同类型的分支,这些分支拥有不同尺度(scale)的卷积,因此能够获得不同大小的感受野,通过不同 scale、不同复杂度的特征提取分支来丰富特征空间。推理阶段结合不同尺寸和复杂度的分离分支来增加特征空间,提升单个卷积的表达能力,实现快速的模型推理。

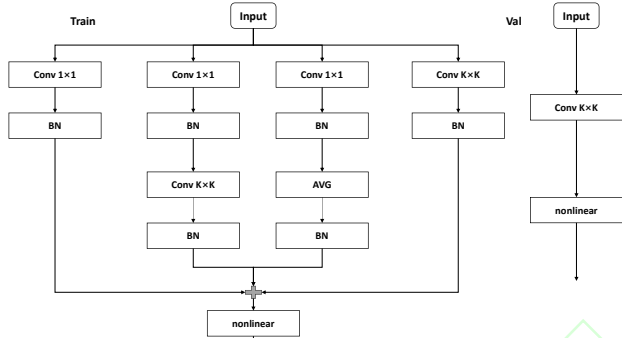


图 2 DBB 结构图

Fig. 2 DBB structure diagram

SE<sup>[24]</sup>注意力机制是为了解决在卷积池化过程中特征图的不同通道所占的重要性不同带来的损失问题。在传统的卷积池化过程中,默认特征图的每个通道是同等重要的,而事实上,不同通道的重要性是有差异的。

如图 3 所示,SE 模块通过引入 Squeeze 和




图 3 SE 注意力

Fig. 3 SE Attention

在 YOLOv5 中,使用 Conv 卷积构造 C3 模块进行特征的提取与分析,如图 4 所示,虽然有一定的效果,但是在面对交通标志时,其特征提取能力有限,与此同时,C3 模块也会占用缓存空间,降低运行速度。引入 DBB 重参数化模块,通过组合不同尺度的卷积来获取不同大小的感受野,提取不同丰富度的特征来充实特征空间。为了增强特征图的重要特征,抑制冗余特征,以此来提高网络的检测性能,同时引入了 SE 注意力机制。使用 DBB 模块替换 C3 中的普通卷积 Conv,并在输出特征图时使用 SE 注意力机制增强重要特征。DBB-SE 结构如图 5 所示。

Excitation 操作,通过自适应地学习每个通道的权重,增强了神经网络的表达能力和性能,使网络能够更有效地学习和利用特征通道之间的关系。它能够自动学习每个通道的权重和重要性。通过学习到的权重,SE 模块可以自适应地调整每个通道的特征在后续网络层中的重要性。这样,网络可以更加关注重要的特征通道,提高特征的判别能力,从而提升模型的性能。

**Squeeze 操作:** 在 Squeeze 操作中,我们对特征图进行全局平均池化,将其压缩成一个特征向量。这可以通过对每个通道的特征图进行平均操作来实现。

**Excitation 操作:** 在 Excitation 操作中,其使用一个全连接层和非线性激活函数来学习每个通道的权重,以捕捉通道之间的关系。

**Scale 操作:** 将学习到的权重向量应用于输入的特征图 X 上的每个通道,将其对应的特征图与权重相乘得到加权后的特征图。

整个 SE 模块的过程可以表示为

$$X' = scale(X) = X \cdot sigmoid(W_2 \cdot ReLU(W_1 \cdot Pool(X))) \quad (1)$$

其中,  $W_1, W_2$  为全连接层的参数;  $Pool$  表示全局平均池化;  $ReLU$  表示 ReLU 激活函数;  $sigmoid$  表示 sigmoid 激活函数。

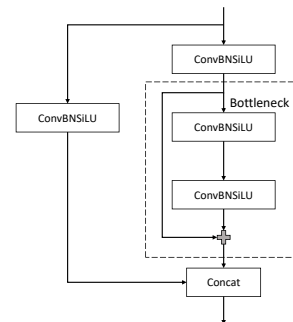


图 4 C3 模块结构

Fig. 4 C3 module structure

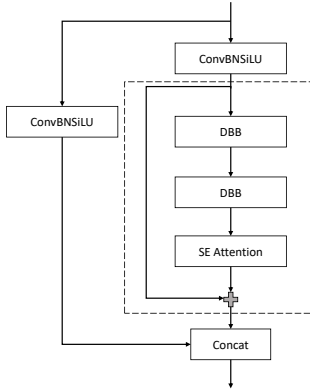


图 5 DBB-SE  
Fig. 5 DBB-SE

## 2.2 SLA

在 Neck 部分引入 SlimNeck<sup>[25]</sup>, 相较于原网络, 减少了参数量, 降低了模型的复杂度。但是模型的学习能力、特征利用率和网络的性能相较于原网络是没有太大区别的。为了提高模型的能力, 在 SlimNeck 的基础上, 加入了 ASF-Neck<sup>[26]</sup>的 SSFF(Scale sequence feature fusion module)模块和 TFE(Triple feature encoding module)模块, 并进行改进, 搭建了新的 Neck 网络 SLA(Slim-Light ASF), 并加入小目标检测层, 充分利用这些不同尺度上的特征信息, 从而获取更加丰富多样的目标特征信息, 有效提升模型的目标理解与表达能力。SLA 首先对不同尺度的特征图(P2, P3, P4, P5)通过 GSConv 处理, 之后用 TFE 模块将这些不同尺度的特征图结合在一起, 形成一个综合特征表示, 提升模型对小目标的感知能力; 继续用 VoVGSCSP 模块来提取和融合特征, 最后通过 SSFF 聚合来自网络不同层的特征, 并通过 Adaptive Add 模块进行自适应拼接。其在 Add 模块中加入注意力机制, 对输入的特征进行特征选择, 强化更有意义的特征, 抑制不相关的特征, 提升特征表达的有效性。其结构如图 6 所示, 在保留 SlimNeck 优越性的同时, 改进其特征融合能力, 保留小目标的特征信息, 将深、浅层的特征进行融合, 进而在较少计算量情况下, 提升模型的表现能力。

SlimNeck<sup>[25]</sup>架构使用了 GSConv 和 VoVGSCSP 模块, 以构建一个高效的神经网络颈部。在这个架构中, 不同尺度的特征图 (P3, P4, P5) 首先通过 GSConv 模块处理, 然后通过上采样 (Upsample) 和拼接 (Concat) 操作与其他尺度的特征图结合。

这样处理后的特征图再次通过 GSConv 模块, 最后使用 VoVGSCSP 模块来进一步提取和融合特征。

为了减少计算复杂性, 但又不影响模型的学习能力, Li 等<sup>[25]</sup>构造了 GSConv, 如下图 6, GSConv 首先输入进行一个普通卷积的下采样, 然后使用 DWConv 深度卷积, 并将两个 Conv 的结果拼接起来, 最后进行 shuffle 操作进行通道洗牌, 得到输出。计算过程见式(2), 其计算成本约为标准卷积(SC)的一半, 但学习能力却与 SC 相当。为了进一步增强网络的学习能力, 进一步使用 GSConv 模块的堆叠设计了 GS BottleNeck 模块。为了提高特征利用效率和网络性能, 使用 GS BottleNeck 设计了 VoVGSCSP 模块。如图 7 所示。

$$F_{GSC} = \text{shuffle} \left( \text{Cat} \left( \text{Conv} \left( X_{C_1} \right)_{\frac{C_2}{2}}, \text{DW} \left( \text{Conv} \left( X_{C_1} \right)_{\frac{C_2}{2}} \right) \right) \right)_{C_2} \quad (2)$$

其中,  $X_{C_1}$  是通道数为  $C_1$  的输入特征图, 其中 Conv 为常规卷积, DW 为 DWConv,  $F_{GSC}$  为 GSC 卷积后输出的特征图, 通道数为  $C_2$ 。




图 6 GSConv 结构图

Fig. 6 GSConv structure diagram

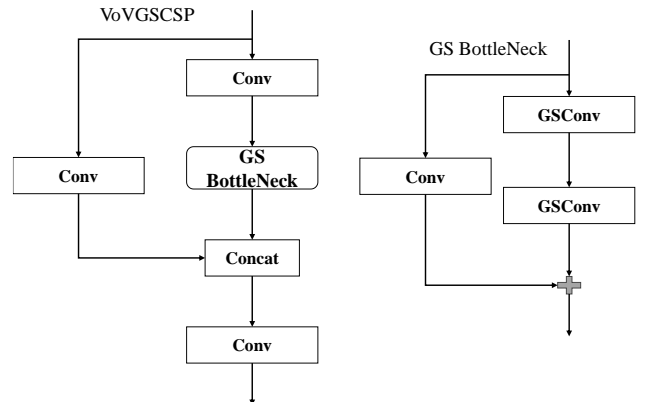


图 7 VoVGSCSP 模块结构图

Fig. 7 VoVGSCSP module structure diagram

尺度序列特征融合(SSFF)模块是用于处理多尺度信息的关键组件。它的主要功能是增强神经网络在提取不同尺度特征时的能力。通过聚合来自网络

不同层的特征，SSFF 模块能够提供更为丰富和细致的特征表示，有助于改善模型在处理不同大小对象时的表现。面对需要精确定位及识别图像中多尺度对象的交通标志检测任务来说，通过 SSFF，模型可以更有效地识别和理解图像中的细节，从而提高整体的检测和识别性能。在 SSSF 中，将 P3、P4 和 P5 特征图归一化到相同大小，上采样，然后堆叠在一起作为输入到 3D 卷积，以组合多尺度特征。并将其作为输入进行自适应拼接。如图 8 所示。




图 8 SSFF 模块  
Fig. 8 SSFF module

Adaptive Add 部分是对来自 SSFF 的特征图进行拼接，作为网络的输出。为了更有效的保留特征，加入了注意力机制，对输入的特征进行特征选择，强化更有意义的特征，抑制冗余或不相关的特征，提升特征表达的有效性。如图 9 所示，在 channel weights 中，首先使用自适应池化操作将每个通道的特征图转换为一个标量值，然后通过一个卷积层和 Sigmoid 激活函数，将这些标量值映射到一个介于 0 和 1 之间的范围，表示每个通道的重要性。Spatial Weights 首先对输入进行水平和垂直方向上的均值池化，得到对应于特征图的行和列的平均值。然后通过卷积层和 Sigmoid 激活函数，计算每个像素位置的注意力权重。

将这两种注意力机制结合在一起，首先对输入进行通道注意力调节，以强调重要的通道信息。然后将调节后的张量与另一个输入张量相加，以保留原始信息。最后，应用空间注意力调节，以进一步细化特征图的表达，得到最终的输出。

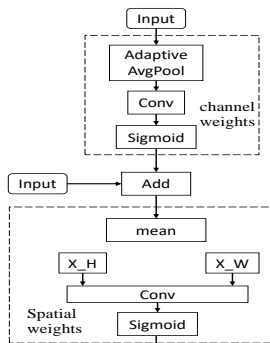


图 9 Adaptive Add  
Fig. 9 Adaptive Add module

机制，它用来来处理不同尺寸的输入特征图。这个模块通过特定的操作，如卷积、批量标准化和激活函数，对来自网络不同层的特征图进行处理，如图 9 所示。然后，它使用上采样和下采样技术来对特征图进行空间尺寸的调整，以确保特征图的尺寸一致。最后，通过一个拼接操作，将这些不同尺度的特征图结合在一起，形成一个综合特征表示，以捕获更多的上下文信息和细节。这样的设计使得网络能够更有效地处理多尺度信息。




图 10 TFE 模块结构图  
Fig. 10 Structure diagram of the TFE module

如图，其将大尺寸特征图（Large）处理由卷积模块，其通道数调整为 1，然后使用混合结构（最大池化 + 平均池化）进行下采样，有助于保留高分辨率特征和交通标志的有效性和多样性。对于小尺寸特征图（Small），卷积模块也用于调整通道数，然后使用动态上采样模块进行上采样，在减少复杂度的同时，有效提升图像处理的效率和质量，有助于保持低分辨率图像的丰富局部特征，并防止小目标特征信息的损失。最后，将大、中、小尺寸具有相同尺寸的 3 个特征图卷积一次，然后按通道进行拼接。即式(3)

$$F_{TFE} = \text{Concat}(F_l, F_m, F_s) \quad (3)$$

其中， $F_{TFE}$  表示 TFE 模块输出的特征图。 $F_l, F_m, F_s$  分别表示大、中和小尺寸的特征图。 $F_{TFE}$  具有与  $F_m$  相同的分辨率，并且通道数是  $F_m$  的三倍。

### 2.2.1 小目标检测层

为了解决交通标志中多为小目标的问题，增加了一个浅层特征图。在对来自网络不同层的网络特征进行 SSFF 聚和后，继续上采样，获取更多的浅层特征，如图 1 所示。在上采样之后，继续使用 TFE 模块对不同尺度的特征进行拼合（P2 层、20、25 层），之后通过 SSFF 模块进行聚合。

### 2.3 IoU-Aware 查询选择

在 YOLOv5 中进行检测时会出现交通标志的错

检、漏检的情况，这是因为在 YOLOv5 中，其采用非极大线性抑制 (Non-maximum suppression, NMS)，通过候选框的分数大小将所有候选框进行从大到小的排序，选择最大分数的检测框 M 后，将其其他大于所设置 IoU (交并比) 的候选框的分数进行置零，只保留一个检测框。NMS 取决于两个超参数得分阈值和 IoU 阈值，特别地，分数低于分数阈值的预测框被直接过滤掉，并且每当 2 个预测框的 IoU 超过 IoU 阈值时，分数较低的框将被丢弃。因此 NMS 算法存在一定的局限性，其使用分类置信度来进行 anchor 排序，由于分类得分和位置置信度的分布不一致，一些预测框具有高分类得分，但不接近 GT 框（当定位还不够准确的时候，类别就已经先学好了的“未对齐”的情况）这导致选择了分类得分高、IoU 得分低的框，高 IoU 但低分类分数的 anchor 被过滤。

为了解决这一问题，引入 RT-DETR (Real-Time DEtection TRansformer)<sup>[27]</sup> 中的 IoU-Aware 查询选择，将 IoU 分数引入分类分支的目标函数，以实现对正样本分类和定位的一致性约束，将预测框与 GT 的 IoU 作为类别预测的标签，使类别的学习受到回归的调制。通过约束模型在训练期间为具有高 IoU 分数的特征产生高分类分数，并为具有低 IoU 得分的特征产生低分类分数。因此，模型根据分类得分选择的特征相对应的预测框具有高分类得分和高 IoU 得分。将检测器的优化目标重新表述为

$$\begin{aligned}\mathcal{L}(\hat{y}, y) &= \mathcal{L}_{\text{box}}(\hat{b}, b) + \mathcal{L}_{\text{cls}}(\hat{c}, \hat{b}, y, b) \\ &= \mathcal{L}_{\text{box}}(\hat{b}, b) + \mathcal{L}_{\text{cls}}(\hat{c}, \hat{b}, \text{IoU})\end{aligned}\quad (4)$$

其中， $\hat{y}, y$  表示预测和 GT， $\hat{y} = \{\hat{c}, \hat{b}\}, y = \{c, b\}$ 。 $c$  与  $b$  表示类别与边界框。

#### 2.4 SIoU

图像的 GT 与模型预测的边界框不匹配会影响模型的检测，而在 YOLOv5 中，使用的 CIoU 损失函数并没有考虑到真实框与预测框之间的方向，收敛较慢、性能较差。采用 SIoU 作为损失函数将，真实框与预测框之间的方向纳入考虑范围，引入预测框与真实框之间的角度向量作为约束。SIoU 收敛速度更快，回归损失降至更低。

SIoU 损失<sup>[28]</sup>函数由 4 个损失构成：角度损失、距离损失、形状损失和 IoU 损失。角度损失描述了

中心点连接与  $x, y$  轴之间的最小角度如图 11 所示，计算公式为

$$\begin{aligned}\Lambda &= 1 - 2 * \sin^2 \left( \arcsin \frac{C_H}{\sigma} - \frac{\pi}{4} \right) \\ \sigma &= \sqrt{(b_{c_x}^{GT} - b_{c_x})^2 + (b_{c_y}^{GT} - b_{c_y})^2}\end{aligned}\quad (5)$$




图 11 SIoU 示例图

Fig. 11 SIoU example diagram

$C_W$  和  $C_H$  分别为中心的宽度差和高度差。 $\sigma$  为真实框和候选框中心点的距离。当中心点在  $x$  轴或  $y$  轴上对齐时， $\Lambda=0$ 。当中心点连接到  $x$  轴  $45^\circ$  时， $\Lambda=1$ 。这一惩罚可以引导锚框移动到目标框的最近的轴上。

距离损失描述了中心点之间的距离，其惩罚代价与角度代价呈正相关，当  $\alpha \rightarrow 0$  时，距离损失的贡献大大降低。相反， $\alpha$  越接近  $\frac{\pi}{4}$ ，距离损失贡献越大，即

$$\begin{aligned}\Lambda &= \sum_{t=x,y} 2 - e^{-\gamma \rho_x} - e^{-\gamma \rho_y} \\ \rho_x &= \left( \frac{b_{c_x}^{GT} - b_{c_x}}{C_W} \right)^2, \rho_y = \left( \frac{b_{c_y}^{GT} - b_{c_y}}{C_H} \right)^2, \gamma = 2 - \Lambda\end{aligned}\quad (6)$$

形状损失这里 SIoU 考虑的是两框之间的长宽比，是通过计算两框之间宽之差和二者之间最大宽之比来定义的，大体思路和 CIoU 类似，只不过 CIoU 考虑的是两框整体形状的收敛，而 SIoU 是以长、宽两个边收敛来达到整体形状收敛的效果。即公式为

$$\Omega = \left( 1 - e^{-w_w} \right)^\theta + \left( 1 - e^{-w_h} \right)^\theta \quad (7)$$

$\theta$  是个可调变量，来表示网络需要对形状这个，给予多少注意力，即占多少权重。



SIoU 总损失如公式 8 所示。

$$L_{Box} = 1 - IoU + \frac{\Delta + \Omega}{2} \tag{8}$$

### 3 实验结果与分析

#### 3.1 实验环境

本次实验使用的硬件平台GPU为NVIDIA RTX3060，显存为12.6 GB，CPU为：6 x E5-2680 v4，内存为28 GB，系统环境为Linux，CUDA版本11.1，在PyTorch v2.0.1、Python 3.10.12版本下对模型进行训练、验证。

网络图片输入大小为 $640 \times 640$ ，Batch-size设置为8，epoch为200。学习率设置为0.0001保持不变，使用优化器AdamW优化网络，初始动量为0.9，权重衰减系数设置为0.0001。

#### 3.2 实验数据

有关于国内交通标志的数据集中，相较于其他数据集，TT100K数据集种类丰富。因此采用TT100K数据集来训练和验证改进的实验算法。TT100K是一个大型的交通标志数据集，单张分辨率为 $2048 \times 2048$ ，拥有数百种标志类别，但是，其中绝大多数类别样本量不足，甚至极少。因此本实验从中筛选了样本个数大于100的45个类别，并对个别类别其进行增补，共获得9176张图片，按8：2的比例划分训练集与验证集。

#### 3.3 评价指标

本实验使用 Recall、Precision、mAP、参数量 (Parma)和计算量(GFLOPs)评价实验指标。Recall，召回率衡量了在所有正例中模型正确预测的概率，召回率与漏报率相对，即召回率越高，漏报率越小；Precision 精确率，也叫查准率，即正确预测为正的占全部预测为正的比例；mAP 是在 IoU 阈值为 0.7 时的所有类别 AP 的平均值。mAP@50:95，表示 IoU 阈值为 0.5 到 0.95 时的平均精度。

#### 3.4 实验结果分析

本实验以 YOLOv5 7.0 版本为基线模型，在此基础上进行改进实验。为了验证所提出的 SAL Neck 的有效性，做了对比实验。在原始模型 YOLOv5 的基础上，做相同的 Backbone、Head 改进，即：IoU-Aware 查询，DBB-SE，选取不同的 Neck 进行实验(图 12)，实验结果见表 1。改进后的

SLA 相较于 ASF，在计算复杂度降低的情况下，检测精度却于其持平。SlimNeck 虽然计算复杂度较低，但其检测精度太差，改进后的 SLA，虽然在复杂度上有所增加，但弥补了其的精度不足。

表 1 颈部网络对比实验

Table 1 Comparative experiments with neck networks				
Neck	Params(M)	GFLOPs	mAP	mAP@50:95
Slim	11.1	21.7	0.757	0.567
ASF	13.5	30.9	0.775	0.577
SLA	13.6	29.5	0.781	0.580




图 12 不同颈部网络对比

Fig. 12 Comparison of different necks

为了选取合适的注意力机制，在表 2 中验证了不同注意力机制对算法模型的影响，选取了不同的注意力机制配合 DBB 模块进行了对比实验，实验结果见表 2。从表 2 可以看出，相较于其他注意力机制，SE Attention 有着更好的精度体现和较小的计算量，实际结果要优于其他注意力机制，对交通标志有更好的适用性。

表 2 注意力模块对比实验

Table 2 Comparative experiment with attention modules			
模型	GFLOPs	mAP(0.7)	mAP@50:95
DBB+EMA	30.1	0.758	0.563
DBB+SE	29.6	0.770	0.571
BB+CA	29.7	0.743	0.548
DBB+SimAM	31.1	0.762	0.576
DBB+CBAM	29.8	0.767	0.570
DBB+ECA	29.8	0.758	0.551

为了验证改进方法对 YOLOv5 模型的影响，对上述改进：IoU-Aware 查询，DBB-SE，SLA，小尺寸检测层，SIoU，在 TT100K 数据集上进行了消融实验以证明改进方法的有效性和必要性。见表 3，相较于原始的 YOLOv5s 模型，在加入 IoU-Aware 查询选择后，模型的性能得到了大幅的提升，mAP 由 60.2%提升到了 75.0%，直接提高了 14.8%，同时

Precision、Recall、mAP@50:95 均得到了提升；在主干部分，加入重参数化结构 DBB，模型的效果有所加强，继续引入 SE 注意力机制后，模型的 mAP 增加了 2.0%，mAP@50:95 增加了 1.5%；在 Neck 部分，引入提出的 SLA Neck,模型可以更好的对获取的特征信息进行处理，在模型复制度降低的情况下，使得 mAP 增加了 1.1%，同时 Precision、Recall、

mAP@50:95 均得到了提升；面对交通标志中存在的大量的小目标，对经过特征融合的特征进行上采样，增加浅层特征后，模型的性能有了很大的提高，模型的 Precision、Recall 分别增加了 1.0%、0.8%，mAP、mAP@50:95 分别增加了 2.6%、3.2%；加入 SIoU 损失函数后，在不改变模型参数量、计算量的情况下依然可以获得 0.5%的 mAP 提升。

表 3 消融实验

Table 3 Ablation experiment

IoU-Aware	DBB	DBB-SE	SLA	小尺寸检测层	SIoU	Precision	Recall	Params(M)	GFLOPs	mAP(0.7)	mAP@50:95
						0.728	0.566	<b>7074853</b>	<b>16.0</b>	0.602	0.446
√						0.845	0.728	11003844	22.8	0.750	0.555
√	√					0.844	0.736	12994788	27.6	0.759	0.563
√	√	√				0.835	0.773	13324772	29.6	0.770	0.570
√	√	√	√			0.855	0.781	13644342	29.5	0.781	0.581
√	√	√	√	√		0.865	0.789	13694324	46.8	0.807	0.613
√	√	√	√	√	√	<b>0.874</b>	<b>0.791</b>	13694324	46.8	<b>0.812</b>	<b>0.615</b>

注：“√”表示在模型中使用了该方法。

如图 13 所示(左边为 YOLOv5 模型，右边为改进后模型)，YOLOv5m 模型，在检测过程中，存在着漏检、检测精度低等问题。在改进后，模型的性能明显得到了提升，不仅实现了高精度，而且还减少了错检、漏检。改进后的模型，可以获取不同大小的感受野，提取不同丰富度的特征来充实特征空间。增强特征图的重要特征，抑制冗余特征，与此

同时关注特征区间，如图 14 所示，相较于 YOLOv5 模型，本文的模型更加关注于目标特征；YOLOv5 的特征关注杂而乱，并没有关注到目标特征，其受环境的影响较大；而本文的模型较为精准，并不受环境所影响，主要集中在目标特征区间。



(a)




图 13 检测效果对比((a)检测前; (b)检测后)

Fig. 13 Comparison chart of detection results ((a) Before testing; (b) After testing)

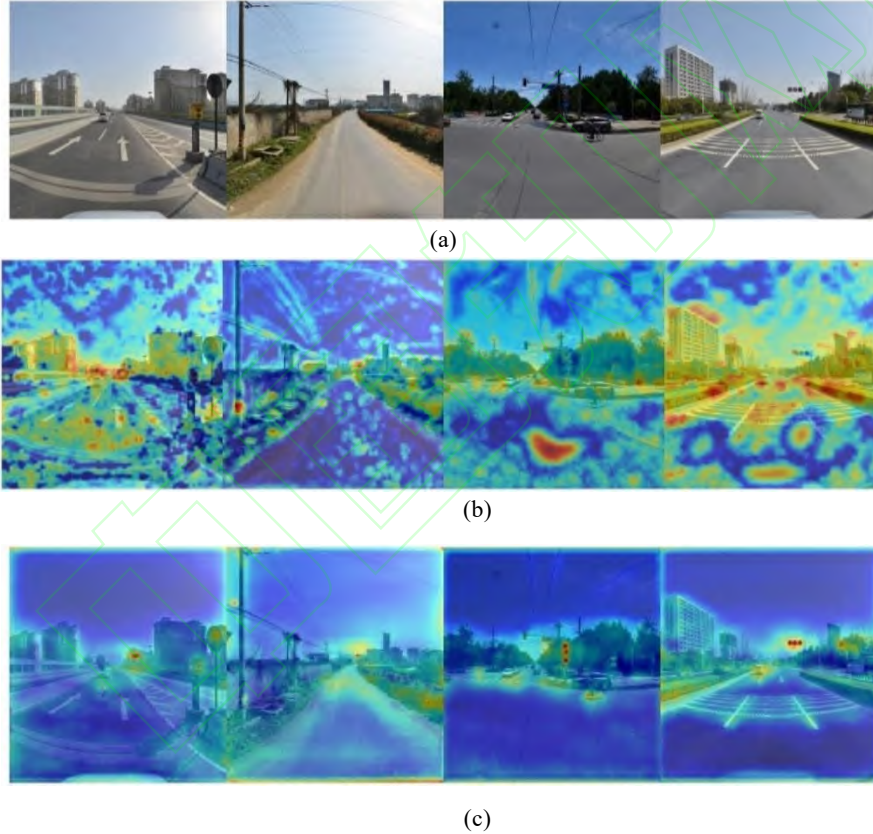


图 14 热力图效果对比((a)原图; (b) YOLOv5 模型; (c)改进后的模型)

Fig. 14 Comparison of heatmap effects ((a) Original drawings; (b) YOLOv5 model; (c) Improved model)

在表 4 中, 使用 TT100K 数据集进行实验对比, 分别选取了单阶段、双阶段、Transformer 算法模型作为对比。由表 4 可知, 相较于 YOLOv5 模型, 其他 YOLO 算法, 在精度上都较低, 不适合于交通标志检测。同时, 两阶段算法无论是在精确率还是在模型的体量上都没有优势; Transformer 算法和一阶段算法有了较大的提升。对于本文所提出的算法, 相比于其他算法, 在参数量、计算量压缩的情况下, 在精度上实现了超越, 相较于 YOLOv5m 计算量减少了 3.6%, 参数量减少了 34.7%, 而 mAP 提升了 13.8%; 相较于 RT-DETR, 计算量减少了 54.9%, 参数量减少了 57.5%, 而 mAP 提升了 1.5%。在最

近的模型算法中, 如文献[31-33]中, 在精度上也是远远落后, 不尽如人意。这些对比证明了所改进算法的有效性与优越性。

为了进一步验证本文所提算法对交通标志的检测性能, 表 5 选取了 CCTSDB 数据集, 进行对比实验, 由表 5 可知, 本文所提出的方法在精度上相较于其他算法有着不错的表现, 领先目前的一些主流算法, 同时, 相较于当前的一些改进算法, 如文献[34-35]也有着较好的表现, 这证明了所提算法的优越性和泛化性。

表 4 TT100K 对比实验

Table 4 TT100K contrast experiment

models	Params/M	GFLOPs	mAP
Faster R-CNN	41.6	195.8	0.551
YOLOv3	61.7	185.3	0.772
YOLOv4	96.9	141.7	0.643
YOLOv5s	7.2	<b>16.0</b>	0.602
YOLOv8s	11.2	28.6	0.589
YOLOv5m	21.0	48.4	0.673
YOLOv6	31.3	--	0.742
YOLOv7	36.6	103.6	0.563
YOLOv7-tiny	6.1	13.1	0.370
YOLOv8	11.2	28.6	0.654
SSD	25.0	274.05	0.268
文献[30]	<b>2.8</b>	--	0.719
文献[31]	--	--	0.752
文献[32]	--	--	0.742
Deformable DETR	40.0	128.0	0.771
RT-DETR-l	32.0	103.6	0.796
Ours	13.7	46.8	<b>0.811</b>

表 5 CCTSDB 对比实验

Table 5 CCTSDB contrast experiment

models	Params/M	GFLOPs	mAP
Faster R-CNN	41.6	195.8	0.757
YOLOv3	61.7	185.3	0.581
YOLOv4	96.9	141.7	0.742
YOLOv5	7.2	16.1	0.798
YOLOv7	36.3	103.6	0.742
YOLOv8	11.2	28.6	0.790
文献[33]	--	--	0.808
文献[34]	<b>2.6</b>	<b>24.7</b>	0.856
文献[35]	8.9	--	0.918
RT-DETR-l	32	103.6	0.821
Ours	13.7	46.8	<b>92.1</b>

## 4 结束语

当前的目标检测算法应用于交通标志时，精度上差强人意，还存在漏检、错检，无法满足于应用。为了提高交通标志方面的检测精度和降低模型的复杂度，我们基于 YOLOv5s 构造了一种新的算法模型。在主干部分，采用重参数化模块 DBB，运用不同尺度 (scale) 的卷积，获得不同大小的感受野，通过不同 scale、不同复杂度的特征提取分支来丰富特征空间，同时引入了 SE 注意力机制来增强特征图的重要特征，抑制冗余特征，以此来提高网络的检测性能；在 Neck 部分，使用 SLA Neck 作为颈部结构，减少参数数量与计算量的同时，融合不同层级的特征信息，捕获更多的上下文信息和细节，分割背景信息，使模型更专注于目标特性区域，改善模型在对面到不同大小对象时的表现，实现精准定位；同时对融合后的特征进行上

采样，获取浅层特征信息；IoU-Aware 查询选择，将 IoU 分数引入分类分支的目标函数，以实现对本样本分类和定位的一致性约束，提升模型的匹配机制，降低错检、漏检现象；还引入 SIOU 作为损失函数，将候选框与真实框之间的方向纳入损失范围，提高检测精度。经过比对，本文的算法模型超越了众多算法模型，有着较好的表现。但是其目前参数量、计算量等较大，不够轻量化，应用起来较为困难，下一步将继续研究降低模型的复杂度的情况下，如何保持精度以及提升检测精度，并将其部署在硬件端，进行应用。

### 参考文献 (References)

[1] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition. 2014: 580–587.

[2] GIRSHICK R. Fast R-CNN[C]//2015 IEEE International Conference on Computer Vision. New York: IEEE Press, 2015: 1440–1448.

[3] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137–1149.

[4] CAI Z W, VASCONCELOS N. Cascade R-CNN: delving into high quality object detection[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2018: 6154–6162.

[5] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2016: 779–788.

[6] REDMON J, FARHADI A. YOLOv3: an incremental improvement[EB/OL]. 2018: arXiv: 1804.02767. <http://arxiv.org/abs/1804.02767>.

[7] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: optimal speed and accuracy of object detection[EB/OL]. 2020: arXiv: 2004.10934. <http://arxiv.org/abs/2004.10934>.

[8] LI C Y, LI L L, JIANG H L, et al. YOLOv6: a single-stage object detection framework for industrial applications[EB/OL]. 2022: arXiv: 2209.02976. <http://arxiv.org/abs/2209.02976>.

[9] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2023: 7464–7475.



- [10] LONG X, DENG K P, WANG G Z, et al. PP-YOLO: an effective and efficient implementation of object detector[J]. 2020.DOI:10.48550/arXiv.2007.12099.
- [11] GE Z, LIU S T, WANG F, et al. YOLOX: exceeding YOLO series in 2021[EB/OL]. 2021: arXiv: 2107.08430. <http://arxiv.org/abs/2107.08430>.
- [12] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot MultiBox detector[C]//European Conference on Computer Vision. Cham: Springer, 2016: 21-37.
- [13] FU C Y, LIU W, RANGA A, et al. DSSD: deconvolutional single shot detector[EB/OL]. 2017: arXiv: 1701.06659. <http://arxiv.org/abs/1701.06659>.
- [14] 张毅, 龚致远, 韦文闻. 基于改进 Faster R-CNN 模型的交通标志检测[J]. 激光与光电子学进展, 2020, 57(18): 181015.
- ZHANG Y, GONG Z Y, WEI W W. Traffic sign detection based on improved faster R-CNN model[J]. Laser & Optoelectronics Progress, 2020, 57(18): 181015 (in Chinese).
- [15] HAN C, GAO G Y, ZHANG Y. Real-time small traffic sign detection with revised faster-RCNN[J]. Multimedia Tools and Applications, 2019, 78(10): 13263-13278.
- [16] 冯爱棋, 吴小俊, 徐天阳. 融合注意力机制和上下文信息的实时交通标志检测算法[J]. 计算机科学与探索, 2023, 17(11): 2676-2688.
- FENG A Q, WU X J, XU T Y. Real-time traffic sign detection algorithm combining attention mechanism and contextual information[J]. Journal of Frontiers of Computer Science and Technology, 2023, 17(11): 2676-2688 (in Chinese).
- [17] 刘紫燕, 袁磊, 朱明成, 等. 融合 SPP 和改进 FPN 的 YOLOv3 交通标志检测[J]. 计算机工程与应用, 2021, 57(7): 164-170.
- LIU Z Y, YUAN L, ZHU M C, et al. YOLOv3 Traffic sign Detection based on SPP and Improved FPN[J]. Computer Engineering and Applications, 2021, 57(7): 164-170 (in Chinese).
- [18] 杨永波, 李栋, 房建东, 等. 面向嵌入式端的轻量级交通信号灯检测算法[J/OL]. 计算机工程与应用, 1-9[2024-03-26].
- YANG Y B, LI D, FANG J D, et al. Lightweight traffic signal light detection algorithm for the embedded terminal [J]. Computer Engineering and Applications, 1-9[2024-03-26].
- [19] 李大湘, 吉展, 刘颖, 等. 改进 YOLOv7 遥感图像目标检测算法[J/OL]. 图学学报, 1-10[2024-04-18].
- LI D X, JI Z, LIU Y, et al. Improving YOLOv7 remote sensing image target detection algorithm [J/OL]. Journal of Graphics, 1-10[2024-04-18].
- [20] DING X H, ZHANG X Y, HAN J G, et al. Diverse branch block: building a convolution as an inception-like unit[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2021: 10881-10890.
- [21] 李跃华, 仲新, 姚章燕, 等. 基于改进 YOLOv5s 的着装不规范检测算法研究[J/OL]. 图学学报, 1-12[2024-04-18].
- LI Y H, ZHONG X, YAO Z Y, et al. Detection of dress code violations based on improved YOLOv5s [J/OL]. Journal of Graphics, 1-12[2024-04-18].
- [22] 胡欣, 胡帅, 马丽军, 等. 基于融合 MBAM 与 YOLOv5 的 PCB 缺陷检测方法[J]. 图学学报, 2024, 45 (01): 47-55.
- HU X, HU S, MA L J, et al. PCB defect detection method based on fusion of MBAM and YOLOv5 [J]. Journal of Graphics, 2024, 45 (01): 47-55.
- [23] 魏陈浩, 杨睿, 刘振丙, 等. 具有双层路由注意力的 YOLOv8 道路场景目标检测方法[J]. 图学学报, 2023, 44 (06): 1104-1111.
- WEI C H, YANG R, LIU Z B, et al. YOLOv8 with bi-level routing attention for road scene object detection [J]. Journal of Graphics, 2023, 44 (06): 1104-1111.
- [24] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2018: 7132-7141.
- [25] LI H L, LI J, WEI H B, et al. Slim-neck by GSConv: a better design paradigm of detector architectures for autonomous vehicles[EB/OL]. 2022: arXiv: 2206.02424. <http://arxiv.org/abs/2206.02424>.
- [26] KANG M, TING C M, TING F F, et al. ASF-YOLO: a novel YOLO model with attentional scale sequence fusion for cell instance segmentation[EB/OL]. 2023: arXiv: 2312.06458. <http://arxiv.org/abs/2312.06458>.
- [27] LV W Y, Zhao Y A, XU S L, et al. DETRs Beat YOLOs on Real-time Object Detection. arXiv preprint arXiv:2304.08069.
- [28] GEVORGYAN Z. SiO loss: more powerful learning for bounding box regression[EB/OL]. 2022: arXiv: 2205.12740. <http://arxiv.org/abs/2205.12740>.
- [29] 曲宸阳, 程艳云. 基于改进 YOLOv7 的交通标志检测算法[J/OL]. 微电子学与计算机, 2024: 1-11. (2024-01-29). <https://kns.cnki.net/kcms/detail/61.1123.TN.20240129.1031.002.html>. QU C Y, CHENG Y Y. Traffic sign detection algorithm based on improved YOLOv7[J/OL]. Microelectronics & Computer, 2024: 1-11. (2024-01-29). <https://kns.cnki.net/kcms/detail/61.1123.TN.20240129.1031.002.html> (in Chinese).
- [30] 熊恩杰, 张荣芬, 刘宇红, 等. 面向交通标志的 Ghost-YOLOv8 检测算法[J]. 计算机工程与应用, 2023, 59 (20): 200-207.
- XIONG E J, ZHANG R F, LIU Y H, et al. Ghost-YOLOv8 Detection Algorithm for Traffic Signs [J]. Computer Engineering and Applications, 2023, 59 (20): 200-207.
- [31] 刘紫燕, 袁磊, 朱明成, 等. 融合 SPP 和改进 FPN 的 YOLOv3 交通标

---

志检测[J]. 计算机工程与应用, 2021, 57(7): 164-170.

LIU Z Y, YUAN L, ZHU M C, et al. YOLOv3 Traffic sign Detection based on SPP and Improved FPN[J]. Computer Engineering and Applications, 2021, 57(7): 164-170 (in Chinese).

[32] 韦强, 胡晓阳, 赵虹鑫. 改进 YOLOv5 的交通标志检测方法[J]. 计算机工程与应用, 2023, 59(13): 229-237.

WEI Q, HU X Y, ZHAO H X. Improved traffic sign detection method for YOLOv5[J]. Computer Engineering and Applications, 2023, 59(13): 229-237 (in Chinese).

[33] 田鹏, 毛力. 改进 YOLOv8 的道路交通标志目标检测算法[J]. 计算机工程与应用, 2024, 60(8): 202-212.

TIAN P, MAO L. Improved YOLOv8 object detection algorithm for traffic sign target[J]. Computer Engineering and Applications, 2024, 60(8): 202-212 (in Chinese).

[34] 杨祥, 王华彬, 董明刚. 改进 YOLOv5 的交通标志检测算法[J]. 计算机工程与应用, 2023, 59(13): 194-204.

YANG X, WANG H B, DONG M G. Improved YOLOv5's traffic sign detection algorithm[J]. Computer Engineering and Applications, 2023, 59(13): 194-204 (in Chinese).

[35] 朱强军, 胡斌, 汪慧兰, 等. 基于轻量化 YOLOv8s 交通标志的检测[J/OL]. 图学学报, 1-10[2024-04-25].

ZHU Q J, HU B, WANG H L, et al. Detection of traffic signs based on lightweight YOLOv8s [J]. Journal of Graphics, 1-10[2024-04-25].