



面向微型交通标志的 ASPC-YOLOv8 检测算法

陈其彬¹, 邓 涛^{2,3,4}, 杨志军¹, 汪世豪¹,
李彦波⁵, 韩振宇⁵, 陈梓山⁵

- (1. 重庆交通大学 机电与车辆工程学院, 重庆 400074;
2. 重庆交通大学 航空学院, 重庆 400074;
3. 绿色航空能源动力重庆市重点实验室, 重庆 400074;
4. 重庆交通大学绿色航空技术研究院, 重庆 400074;
5. 凌云工业股份有限公司, 上海 201708)

摘 要:针对在部分遮挡和复杂背景下的微型交通标志误检、漏检等问题,提出一种基于 YOLOv8s 的交通标志检测框架。构建空间自适应金字塔卷积模块(ASPC)代替 Neck 所有 Conv 模块,设计全新的 ASPC2f 模块代替部分 C2f 模块,减少了模型参数量,提升了检测性能;为解决在检测小目标时因尺度不一致而导致的语义信息损失问题,引入小目标检测层,以增强深层和浅层语义信息的有效融合;使用 EIOU 代替原来的边界框损失函数,提升网络边界框回归性能。经实验,该方法在 TT100K 交通标志数据集上平均精度均值(mAP)达到 89.7%,相较于原模型提升 6.2 个百分点,微型目标平均精度均值相对提升 9.4 个百分点,参数量降低 2.6 MB。

关键词:交通标志检测;小目标检测;空间金字塔卷积;特征融合

中图分类号:U495

文献标识码:A

文章编号:1674-8425(2024)05-0055-06

0 引言

随着智能驾驶辅助系统的快速发展,交通标志检测系统(TSDS)作为其重要组成部分,也是目前的研究热点之一^[1]。然而,部分遮挡、光照不明、角度折叠等复杂现实场景给目标微小的交通标志检测增加了难度。

传统的交通标志识别算法^[2]利用图像的颜色、形状或者基于多特征融合等方法从候选区域提取特征然后输入分类器来获取结果。随着深度学习的发展,国内外学者结合卷积神经网络对交通标志目标检测做了大量研究,Zhang 等^[3]提

出基于多尺度注意模块所改进的 Cascade RCNN 交通标志检测算法,通过 dot-product 和 softmax 获得加权的多尺度特征,并将其相加以细化特征,突出交通标志特征,提高交通标志检测的准确性;Manzari 等^[4]提出利用 Transformer 搭建局部机制金字塔模块并应用于 Cascade RCNN,大大提升了检测精度;Liang 等^[5]提出了一种改进的稀疏 R-CNN 检测算法,将坐标注意模块与 ResNeSt 相结合,构建特征金字塔来修改主干,使提取的特征能够集中在重要信息上,提高了检测精度。然而,以上方法均采用两阶段神经网络算法,虽然提升了精度,但缺乏实时性。

基于回归的交通标志检测算法相较于两阶段算法不仅

收稿日期:2023-10-23

基金项目:国家自然科学基金项目(52275051);重庆市教育委员会科学技术研究重点项目(KJZD-K202000701);重庆交通大学自然科学类揭榜挂帅项目(XJ2023000701);重庆市自然科学基金项目(CSTB2022NSCQ-LZX0068)

作者简介:陈其彬,男,硕士研究生,主要从事计算机视觉、目标检测研究,E-mail:1969566217@qq.com;通信作者 邓涛,博士,教授,主要从事新能源与智能网联汽车控制、新能源动力系统设计研究,E-mail:d82t722@cqjtu.edu.cn。

本文引用格式:陈其彬,邓涛,杨志军,等.面向微型交通标志的 ASPC-YOLOv8 检测算法[J].重庆理工大学学报(自然科学),2024,38(5):55-60.

Citation format:CHEN Qibin, DENG Tao, YANG Zhijun, et al. ASPC-YOLOv8 detection algorithm for miniature traffic signs[J]. Journal of Chongqing University of Technology (Natural Science), 2024, 38(5): 55-60.

能很好地满足实时性要求,还能达到一定的精度。Zhang 等^[6]为了满足实时性要求,提出 MSA_YOLOv3,它使用混合图像增强,并引入了多尺度空间金字塔池化模块来学习更丰富的特征。Yuan 等^[7]提出了 YOLOv5s-A2,使用特征金字塔网络(FPN)的路径聚合模块,用于建立新的水平连接并构建注意力检测头,解决跨尺度融合中的混叠效应,增强预测特征的特征。Gao 等^[8]在解决小目标问题上提出自适应关注的空间特征融合模块,来学习不同尺寸下的不同特征语义信息。朱开等^[9]基于 YOLOv5 通过引入注意力机制和损失函数等方式,力求检测的高精度与高时效性。YOLOv8 作为 YOLO 系列最新的模型,具有更高的精度和更好的时效性,在交通标志检测上也有所应用,如熊恩杰等^[10]利用 Ghostnet 对其进行改进,解决传统算法精度低、检测不准确等问题。综上所述,改进的方法都在检测性能上得到了更好的提升,但是所提出的方法并没有考虑交通标志所面临的环境因素。因此在面对交通标志在被遮挡、暗光线和复杂背景等环境中进行远距离检测时会出现大量的误检和漏检问题。

针对以上问题,选取性能优越的 YOLOv8s 作为基础检测框架进行改进,以此来解决当前检测算法对处于复杂环境下的微小交通标志进行识别时精度低、速度慢等问题。主要贡献如下:

- 1) 构建自适应空间金字塔卷积模块,并利用其搭建 ASPC2f 模块,使模型自适应关注提取的特征信息,更具鲁棒性,同时达到轻量化效果,减少模型参数量。
- 2) 引入 160×160 的微型目标检测头,增加上下特征提取层语义信息融合度,提升微型目标检测精度。
- 3) 使用基于嵌入特征的 EIOU 损失函数替换原来的边框回归损失函数,更好地处理目标框的旋转、尺度和形状变化,提升回归效率。

1 YOLOv8 检测算法改进策略

由于主干网络已经证明了在分类和其他问题上具有强大的特征提取能力,因此保留了原始框架。针对由 FPN^[10]和 PAN^[11]组成的颈部网络,重复采用上下采样、拼接和点乘等策略聚合目标特征信息时造成的小目标信息缺失问题,通过在原颈部网络基础上构建并引入空间自适应金字塔卷积模块(ASPC)、空间自适应金字塔卷积瓶颈模块(ASPC2f)、小目标检测头和 EIOU Loss^[12]等构建新的颈部网络,因此本节详细介绍了上述模块。改进后的 YOLOv8 网络结构如图 1 所示。

1.1 空间自适应金字塔卷积模块

深度卷积神经网络通常由大量卷积层组成,但是会出现 2 个问题:1)随着卷积层的加深,通道数会变得很大,这将导致每个通道之间的信息丢失,致使拥有少量像素点的目标被忽略;2)使用多卷积层的网络会增加参数,增大硬件要求。针对以上问题,设计轻量化空间金字塔卷积模块(ASPC),该

模块通过自适应注意力融合强调不同尺度下不同特征图的重要区域,以加强稀疏信息权重,防止信息过滤,其结构如图 2 所示。

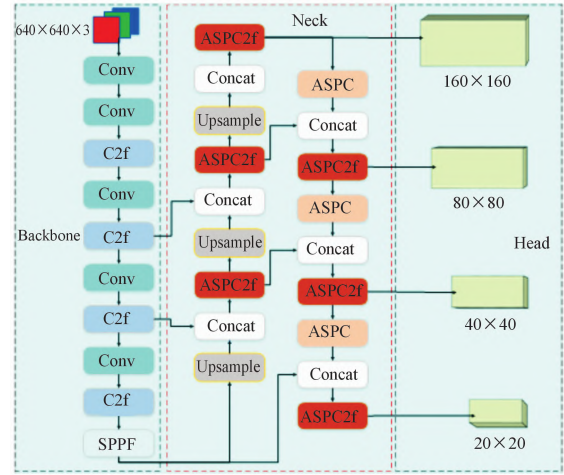


图 1 ASPC-YOLOv8 模型结构示意图




图 2 ASPC 模型结构

在卷积神经网络中,不同大小卷积层会产生不同尺寸和不同的信息丰富度。因此将 $f_1 \sim f_4$ 分别使用 1×1 、 5×5 、 7×7 、 9×9 的卷积核且 f_i 输出数据作为 $f_2 \sim f_4$ 输入数据,从而获得局部特征和全局特征,用 $f = \{f_i | i = 1, \dots, 4\}$ 表示, f_i 是普通卷积层的输出,表示为:

$$f_i = \text{Conv}(ch_{in}, ch_{out}, k_i) \quad (1)$$

式中: $\text{Conv}(\cdot)$ 是普通卷积操作; ch_{in} 、 ch_{out} 、 k_i 分别表示卷积层输入通道数、输出通道数和卷积核大小。通常使用简单的元素求和或级联方法来集成每层卷积后所产生特征图富含的不完整信息,这可能导致不同尺度的特征之间语义不一致,导致融合的特征图信息冗余或缺失。为了解决这个问题,引入 SimAM^[13]来自适应学习不同特征图的通道及空间注意力权重。该模块从网络层中直接推理出三维的注意力权重然后反过来优化该网络层,改善卷积网络在空间和通道同时变化时的灵活性和有效性,如图 3 所示。

通过自适应权重进行拼接得到的特征信息 $s(f) \in \mathbb{R}^{H_k \times W_k \times C}$, H_k, W_k 表示 G_k 的分辨率, C 代表通道数, 表示为:

$$S(f) = f_1(S_{G_k}) + \sum_{i=2}^4 f_i(f_{i-1}(S_{G_k})) \quad (2)$$

式中, S_{G_k} 表示 G_k 的空间及通道注意力图。

融合初始特征信息权重后得到的空间自适应金字塔融合的输出特征信息 F_k 为:

$$F_k = S(f) \otimes S(G_k) \quad (3)$$

为了进一步减少模型参数量、提升检测速度, 在 $f_1 \sim f_4$ 中引入 GhostNet^[14] 中的线性运算, 通过固有特征映射来节省计算成本。具体来说就是每个卷积生成 m 个固有特征映射, 如图 4 所示。每个固有特征映射利用线性运算生成 s 个冗余特征映射, 其中 $s-1$ 个特征冗余, 过程如下所示:

$$Y_{ij} = \Phi_{ij}(y_i), \quad \forall i = 1, \dots, m; j = 1, \dots, s \quad (4)$$

式中: y_i 是 Y_i 的第 i 个固有特征图; $\Phi_{ij}(y_i)$ 是第 i 个特征图的第 j 个冗余映射。根据式 (4) 得到输出特征数 $n = m * s$ 。ASPC 通过多个不同的线性操作 (卷积核等于 $5 \times 5, 7 \times 7, 9 \times 9$) 来获取多尺寸的固有特征图。




图 3 SimAM 原理示意图




图 4 ASPC 中卷积固有特征映射模型

1.2 ASPC2f 模块

针对网络末端送入检测头的特征图分辨率较低, 小目标特征信息模糊等问题, 受 TPH-YOLOv5^[15] 模型改进的启发, 使用空间自适应金字塔卷积瓶颈模块 (ASPC2f) 来替换 YOLOv8 中的 c2f 瓶颈块, 作为直接输入检测头的尾部特征信息提取模块, 丰富特征图信息同时降低计算和内存成本。如图 5 所示, ASPC2f 模块是对残差特征进行学习的主要模块, 其结构分为 2 支: 一支经过指定多个 ASPCBottleneck 堆叠和 2 个卷积层, 另一支仅经过一个普通卷积模块, 最后通过拼接得到多层次特征输出。ASPCBottleneck 根据残差结构设计, 将普通卷积替换为 ASPC。后续实验证明与原始瓶颈

块相比, ASPC2f 更能捕获全局信息和丰富的语义信息。

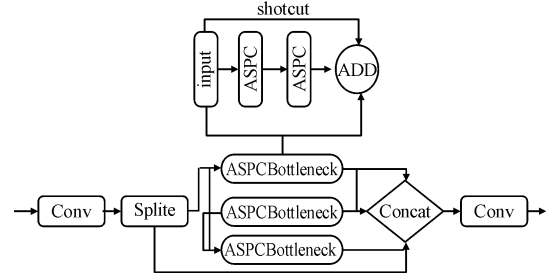


图 5 ASPC2f 模块结构

1.3 小目标检测头

研究 TT100K^[16] 数据集后, 发现它包含许多微小的实例, 并且在 YOLOv8 中经历多次下采样, 导致原网络中的检测头对小物体检测能力较差, 因此添加小目标检测层, 包括检测头和负责特征信息提取的 ASPC2f 模块。以 640×640 输入图像的尺寸为例, 该层特征图尺寸将达到 160×160 , 对应的输出特征图有最大的尺寸和足够的特征信息, 避免了在下采样过程中小目标信息被过滤, 有效地找到目标。该方法会带来一些计算量, 但是相对于给网络识别能力带来的提升是可以接受的。

1.4 EIIOU 损失函数

YOLOv8 模型使用的回归损失是由 DFL + CIOU Loss 组成。其中 CIOU 损失函数存在纵横交并比模糊, 忽略正负样本不平衡等问题影响模型收敛。在 YOLOv8 中引入 EIIOU 损失函数代替 CIOU, 在 CIOU 的基础上分别计算宽高的差异值取代纵横比, 同时引入 Focal Loss 解决难易样本不平衡的问题, 进而加速了模型收敛。EIIOU 的定义式为:

$$L_{EIIOU} = L_{IOU} + L_{dis} + L_{asp} = 1 - IOU + \frac{d^2(b^p, b^{gt})}{(w^c)^2 + (h^c)^2} + \frac{d^2(w^p, w^{gt})}{(w^c)^2} + \frac{d^2(h^p, h^{gt})}{(h^c)^2} \quad (5)$$

式中: L_{IOU} 为交并比损失; L_{dis} 是距离损失; L_{asp} 为方向损失; w^c, h^c 分别为预测框和目标框最小外界矩形的宽高; $d^2(b^p, b^{gt})$ 为预测框和目标框欧式距离; $d^2(w^p, w^{gt})$ 为预测框和目标框宽度差值; $d^2(h^p, h^{gt})$ 为预测框和目标框高度差值。引入 Focal-loss 后其定义式为:

$$L_{Facal-EIOU} = IOU^r L_{EIIOU} \quad (6)$$

式中: IOU 为交并比; r 为抑制参数, 设置为 0.5 时效果最好。

2 实验结果

2.1 数据及实施细节

TT100K 数据集包含 9 167 张图像, 涵盖了不同照明和天气条件下的 162 种交通标志类别, 但大多数实例个数较少因此从 TT100K 数据集中选择超过 100 个实例的 45 种类型用于交通标志检测研究, 数据集都按照 7:3 划分训练集和验

证集。

本次实验的环境为 CUDA11.3 + pytorch1.11.0 + python3.8, 实验设备为 NVIDIA GeForce RTX 3060Ti。主要超参数的设置, 初始学习率为 0.01, 训练周期为 500, 图像输入大小为 640×640 , 批量大小为 8。模型训练期间不使用预训练权重并且所有其他细节均遵循 YOLOv8 测试所使用的标准程序。

2.2 评价指标

对于 TT100K 数据集, 使用固定的交并集 (*IOU*) 值为 0.5 来计算 mAP, 同时使用 COCO^[17] 评价指标中当 $IOU = 0.5:0.95$ 时, AP_s (实例面积小于 32×32 的 AP), AP_m (实例面积大于 32×32 小于 96×96 的 AP) 和 AP_l (实例面积大于 96×96 的 AP) 来评估模型在不同尺寸的检测性能, 验证算法对小目标检测的有效性。其计算公式为:

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (7)$$

$$AP_i = \int_0^1 (P_i \cdot R_i) \quad (8)$$

式中, P_i 和 R_i 分别表示检测类别 i 的准确率和召回率。

$$Precision = \frac{TP}{TP + FP} \quad (9)$$

$$Recall = \frac{TP}{TP + FN} \quad (10)$$

式中: TP 为正确检测次数; FP 为错误检测次数; FN 为漏检交通标志次数。

2.3 检测性能和效率

图 6 展示了 YOLOv5s、YOLOv8s 和改进后的 YOLOv8s 在训练过程中 mAP 变化。与其他 2 个模型相比, 改进后的模型在前 150 轮 mAP 值上升最快, 在 150 轮后缓慢上升, 最终稳定在 0.897 左右。从以上论述可以看出改进后的模型在训练过程中表现最优。




图 6 mAP 曲线

为验证文中提出模型的优越性, 在 TT100K 上将 ASPC-YOLOv8 与其他优秀方法在相同条件下利用 mAP 和参数量进行了比较, 如表 1 所示。

根据表 1 可以看出, 与 YOLOv5-L、Faster R-CNN、A-YOLOv4^[18]、YOLOv5s^[19]、YOLOv7-tiny^[20]、YOLOv8s 相比, ASPC-YOLOv8 无论在精度上还是在参数量上都更占优。尽

管 ASPC-YOLOv8 的参数量比 YOLOv5s 和文献[10]中的方法有所增加, 但是 mAP 指标分别高出了 8.4 个百分点和 4.8 个百分点。实验表明本文中改进的算法实现了高精度和快速的交通标志检测。

表 1 在 TT100K 上不同方法的性能对比

模型	mAP	输入尺寸	参数量/M
YOLOv5-L	86.8	640×640	44.0
Faster R-CNN	72.9	640×640	109.0
A-YOLOv4	86.1	608×608	30.0
YOLOv5s	81.3	640×640	7.1
YOLOv7-tiny	47.6	640×640	12.5
YOLOv8s	83.5	640×640	11.1
文献[10]	84.9	640×640	6.1
ASPC-YOLOv8	89.7	640×640	8.5

为进一步验证本文中改进方法的泛化能力, 将文中所提到的改进方法应用在 YOLOv5 上, 并使用 mAP、Precision (P)、Recall (R)、参数量和 COCO 中 AP_s 、 AP_m 、 AP_l 作为评价指标进行结果分析, 如表 2 所示。改进的 YOLOv8 模型比原模型的 mAP 值提升了 6.2 个百分点, 而按照同样方法改进的 YOLOv5, mAP 值也提升了 5.3 个百分点, 同时参数量有所减少。尽管在中型和大型目标检测方面提升不够明显, 但在小目标检测能力方面, 改进的 YOLOv8s 和改进的 YOLOv5s 的 AP_s 比改进前分别提升了 9.4 和 5.2 个百分点, 达到了模型设计的目的。通过以上分析可以证明本文中改进模型的方法在提升小目标检测能力上表现突出。

表 2 改进模型与原模型对比

模型	mAP	P	R	AP_s	AP_m	AP_l	参数量/M
YOLOv5s	81.3	79.5	78.3	48.3	68.0	83.6	7.1
改进 YOLOv5s	86.6	85.4	82.3	53.5	70.9	84.0	6.7
YOLOv8s	83.5	82.0	77.6	46.9	72.7	83.1	11.1
改进 YOLOv8s	89.7	88.2	83.5	56.3	74.2	85.1	8.5

为验证 ASPC-YOLOv8 算法各模块改进的有效性, 在 YOLOv8 模型的基础上, 引入 ASPC 和 ASPC2f、小目标检测层和 EIOU 损失函数, 进行消融实验, 并以 mAP 作为评价指标, 如表 3 所示。在单独引入构建的 ASPC 及 ASPC2f 后, mAP 提升 4.3 个百分点; 在单独引入小目标检测层后, mAP 提升 3.9 个百分点; 在单独更换 EIOU 损失函数后, mAP 提升 0.7 个百分点, 同时根据图 7 所示, YOLOv8s 在 500 轮次的训练过程中损失函数一直处于缓慢下降状态, 没有趋于平稳, 而更换 EIOU 后, 损失函数在 150 轮左右开始趋于稳定, 更快地趋于收敛, 达到了改进的目的; 在不使用 EIOU 损失函数而同

时引入前 2 种方法时,mAP 提升了 5.8 个百分点;最后同时引入 3 种改进方法后,mAP 提升了 6.2 个百分点。综上所述,3 类改进方法都给原模型带来了提升,证明了方法的有效性。

表 3 消融实验

模型	SPC\SPC2f	小目标检测层	EIOU	mAP
YOLOv8s	×	×	×	83.5
优化模型 1	✓	×	×	87.8
优化模型 2	×	✓	×	87.4
优化模型 3	×	×	✓	84.2
优化模型 4	✓	✓	×	89.3
本文模型	✓	✓	✓	89.7

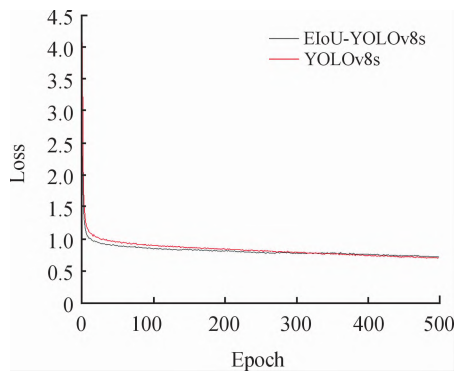


图 7 Loss 曲线

为了直观地展示改进后模型的检测效果,将 YOLOv5s、YOLOv8s 和 ASPC-YOLOv8 对 3 种处于不同情况的交通标志检测结果进行可视化对比,结果如图 8 所示(A、B 中左侧目标皆不属于 45 类检测目标)。



图 8 在 TT100K 数据集上的检测结果对比

根据 A 组实验结果对比,在角度折叠变形的情况下 ASPC-YOLOv8 避免了 YOLOv5s 的漏检和 YOLOv8s 的错检,

准确地检测到目标;根据 B 组实验结果,在对光线变化暗淡时远端目标的检测中 ASPC-YOLOv8 检测精度最高;根据 C 组实验结果对比,在目标处于复杂背景中时,ASPC-YOLOv8 避免了其他模型的漏检问题,以较优的检测精度识别到目标。综上所述,ASPC-YOLOv8 很好地解决了在光照不明、角度折叠和复杂背景等情况下对远端目标出现的误检漏检问题。

3 结论

针对复杂背景下远端交通标志检测容易出现误检、漏检问题,通过构建轻量化空间金字塔卷积模块替换模型颈部的普通卷积,将 ASPC 模块集成到 C2f 瓶颈块中构建 ASPC2f 模块用于网络颈部替换 C3 模块,添加小目标检测,引入 EIOU 损失函数。通过仿真实验验证,改进的模型相较于原模型在准确度上提升 6.2 个百分点,在针对远端小目标检测上提升了 9.4 个百分点且模型参数量有所减少,是一种快速、高效的交通标志检测模型。但是在改进算法时对中大型目标提升不够明显并且没有对该数据集下 162 类进行识别,下一步将进一步对网络进行优化。

参考文献:

- [1] 茅智慧,朱佳利,吴鑫,等. 基于 YOLO 的自动驾驶目标检测研究综述[J]. 计算机工程与应用,2022,58(15):68-77.
- [2] YANG Y,LUO H L,XU H R,et al. Towards real-time traffic sign detection and classification[J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 17(7): 2022-2031.
- [3] ZHANG J M,XIE Z P,SUN J,et al. A cascaded R-CNN with multiscale attention and imbalanced samples for traffic sign detection[J]. IEEE Access,2020,8:29742-29754.
- [4] MANZARI O N,BOUDESCH A,SHOKOUHI S B. Pyramid transformer for traffic sign detection[C]//2022 12th International Conference on Computer and Knowledge Engineering (ICCKE). IEEE,2022:112-116.
- [5] LIANG T J,BAO H,PAN W G,et al. Traffic sign detection via improved sparse R-CNN for autonomous vehicles[J]. Journal of Advanced Transportation,2022,2022:3825532.
- [6] ZHANG H B,QIN L F,LI J,et al. Real-time detection method for small traffic signs based on Yolov3[J]. IEEE Access,2020,8:64145-64156.
- [7] YUAN X,KUERBAN A,CHEN Y X,et al. Faster light detection algorithm of traffic signs based on YOLOv5s-A2[J]. IEEE Access,2023,11:19395-19404.
- [8] GAO E F,HUANG W G,SHI J J,et al. Long-tailed traffic sign detection using attentive fusion and hierarchical group softmax[J]. IEEE Transactions on Intelligent Transportation

- Systems, 2022, 23(12): 24105 – 24115.
- [9] 朱开, 陈慈发. 基于 YOLOv5 的雾霾天气下交通标志识别[J]. 电子测量技术, 2023, 46(8): 31 – 37.
- [10] 熊恩杰, 张荣芬, 刘宇红, 等. 面向交通标志的 Ghost-YOLOv8 检测算法[J]. 计算机工程与应用, 2023, 59(20): 200 – 207.
- [11] LIN TSUNG-YI, DOLLAR PIOTR, GIRSHICK ROSS, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2017: 2117 – 2125.
- [12] LIU S, QI L, QIN H F, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2018: 8759 – 8768.
- [13] ZHANG Y F, REN W Q, ZHANG Z, et al. Focal and efficient IOU loss for accurate bounding box regression[J]. Neuro Computing, 2022, 506: 146 – 157.
- [14] YANG L X, ZHANG R Y, LI L D, et al. SimAM: a simple, parameter-free attention module for convolutional neural networks[C]//International Conference on Machine Learning. PMLR, 2021: 11863 – 11874.
- [15] HAN K, WANG Y H, TIAN Q, et al. Ghostnet: More features from cheap operations[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2020: 1580 – 1589.
- [16] ZHU X K, LYU S C, WANG X, et al. TPH-YOLOv5: Improved YOLOv5 based on transformer prediction head for object detection on drone-captured scenarios[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. IEEE, 2021: 2778 – 2788.
- [17] ZHU Z, LIANG D, ZHANG S H, et al. Traffic-sign detection and classification in the wild[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2016: 2110 – 2118.
- [18] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft COCO: common objects in context[M]//Computer Vision-ECCV 2014. Cham: Springer International Publishing, 2014: 740 – 755.
- [19] LI Y, LI J G, MENG P. Attention-YOLOV4: a real-time and high-accurate traffic sign detection algorithm[J]. Multimedia Tools and Applications, 2023, 82(5): 7567 – 7582.
- [20] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2023: 7464 – 7475.

ASPC-YOLOv8 detection algorithm for miniature traffic signs

CHEN Qibin¹, DENG Tao^{2,3,4}, YANG Zhijun¹, WANG Shihao¹,
LI Yanbo⁵, HAN Zhenyu⁵, CHEN Zishan⁵

(1. School of Mechatronics & Vehicle Engineering, Chongqing 400074, China;

2. School of Aeronautics, Chongqing Jiaotong University, Chongqing 400074, China;

3. Chongqing Key Laboratory of Green Aviation Energy and Power, Chongqing 400074, China;

4. The Green Aerotechnics Research Institute of Chongqing Jiaotong University, Chongqing 400074, China;

5. Lingyun Industrial Co., Ltd., Shanghai 201708, China)

Abstract: To address the misdetection and omission of miniature traffic signs under partial occlusion and complex background, this paper proposes a traffic sign detection framework based on YOLOv8s. First, the adaptive spatial pyramid convolution module (ASPC) is built to replace the Neck part of the Conv module. A new ASPC2f module is designed to replace the part of the C2f module, reducing the number of model parameters and improving the detection performance. To mitigate the semantic information loss due to the inconsistency of scale in detecting the miniature targets, a miniature target detection layer is introduced to enhance the effective fusion of deep and shallow semantic information. Finally, the EIOU is employed to replace original bounding box loss function to improve the network bounding box regression performance. Our experimental results show the method achieves 89.7% mean average precision (mAP) on the TT100K traffic sign dataset, 6.2 percentage points higher compared to that of the original model. Meanwhile, it is 9.4 percentage points higher in the mean average precision of the microtargets and reduces the number of parameters by 2.6 MB.

Key words: traffic sign detection; small target detection; spatial pyramid convolution; feature fusion

(责任编辑 卢 燕)